

Yazılım Laboratuvarı 1. Proje Ödevi:

Kocaeli Yerel Haber Harita Sistemi

Kağan Can Kaba

200201049

Kocaeli Üniversitesi

Bilgisayar Mühendisliği Bölümü

Kocaeli, Türkiye

200201049@kocaeli.edu.tr

Özet

Bu proje kapsamında, Kocaeli ili sınırları içerisinde yayınlanan yerel haber sitelerinden belirli haber türlerine ait güncel haberlerin otomatik olarak toplanması, işlenmesi, sınıflandırılması ve harita üzerinde görselleştirilmesini sağlayan bir masaüstü uygulaması geliştirilmiştir. Sistem; web scraping teknikleri kullanılarak dört farklı yerel haber kaynağından son üç güne ait haberleri çekmekte, anahtar kelime tabanlı sınıflandırma ile haberleri beş farklı kategoriye (trafik kazası, yangın, elektrik kesintisi, hırsızlık, kültürel etkinlikler) ayırmakta ve konum bilgisi çıkarımı yaparak Google Maps üzerinde marker'lar ile görselleştirmektedir. Veriler MongoDB NoSQL veritabanında saklanmakta, metin benzerliği analizi ile mükerrer haberler tespit edilerek birleştirilmektedir. Python programlama dili ve Tkinter grafik arayüz kütüphanesi ile geliştirilen uygulama, kullanıcıya haber türü, ilçe ve zaman aralığına göre dinamik filtreleme imkânı sunmaktadır.

Anahtar Kelimeler—Web scraping, doğal dil işleme, haber sınıflandırma, coğrafi bilgi sistemi, MongoDB, Google Maps, Python, Kocaeli.

I. Giriş

Günümüzde şehir yaşamı trafik kazaları, yangınlar, elektrik kesintileri, hırsızlık olayları ve kültürel etkinlikler gibi pek çok dinamik olaydan etkilenmektedir. Bu olaylar genellikle yerel haber siteleri ve dijital medya platformları aracılığıyla kamuoyuna duyurulmaktadır. Ancak bu bilgilerin farklı kaynaklarda dağınık halde bulunması, vatandaşların güncel olaylara bütüncül ve hızlı bir şekilde erişmesini zorlaştırmaktadır [6].

Türkiye’de yerel gazetecilik, özellikle dijitalleşme süreciyle birlikte önemli bir dönüşüm geçirmektedir. Kocaeli gibi büyük sanayi şehirlerinde, günlük yaşamı etkileyen olayların sayısı ve çeşitliliği oldukça fazladır. Bu durum, haberlerin tek bir platform üzerinden takip edilmesini zorlaştırmaktadır. Web scraping teknolojileri, bu dağınık bilgi kaynaklarını otomatik olarak tarayarak yapılandırılmış veri elde etmeyi mümkün kılmaktadır [1].

NoSQL veritabanları, özellikle MongoDB, esnek şema yapısı ve JSON benzeri doküman formatı sayesinde web scraping ile elde edilen heterojen verilerin saklanmasıyla ilgili veritabanlarına kıyasla önemli avantajlar sunmaktadır [10]. Benzer şekilde, coğrafi bilgi sistemleri (GIS) ve harita

API’leri, konum tabanlı verilerin görselleştirilmesinde güçlü araçlar sağlamaktadır [3].

Bu çalışmada, Kocaeli ili kapsamında yayın yapan dört farklı yerel haber sitesinden (Çağdaş Kocaeli, Özgür Kocaeli, Ses Kocaeli ve Bizim Yaka) belirli haber türlerine ait güncel haberlerin otomatik olarak toplanması, sınıflandırılması ve harita tabanlı bir arayüz üzerinde görselleştirilmesi amaçlanmıştır.

Geliştirilen sistem, web scraping yöntemiyle haber kaynaklarının arşiv sayfalarından son üç güne ait haberleri toplamaktadır. Toplanan haberler, metin ön işleme adımlarından geçirildikten sonra anahtar kelime tabanlı bir sınıflandırma algoritması ile beş farklı haber türüne ayrılmaktadır [5]. Konum bilgisi çıkarımı ve Google Geocoding API entegrasyonu sayesinde, haberler coğrafi koordinatlara dönüştürülerek harita üzerinde işaretlenmektedir. Tüm veriler MongoDB NoSQL veritabanında saklanmakta ve TF-IDF tabanlı cosine similarity yöntemi ile mükerrer haberler tespit edilerek birleştirilmektedir [8].

Raporun geri kalan kısmı şu şekilde organize edilmiştir: Bölüm II’de kullanılan yöntemler, Bölüm III’te arayüz konsepti, Bölüm IV’te veritabanı yapısı, Bölüm V’te API entegrasyonu, Bölüm VI’da sonuçlar ve Bölüm VII’de yazar katkıları sunulmaktadır.

II. Yöntem

A. Web Scraping Modülü

Haber toplama işlemi, her bir kaynak sitenin arşiv sayfaları üzerinden gerçekleştirilmektedir. Dört KOGA medya altyapısını kullanan site için arşiv URL formatı `https://SITE/arsiv/YYYY-MM-DD` şeklindedir. Her arşiv sayfasından `/haber/ID/slug` formatındaki haber linkleri BeautifulSoup kütüphanesi ile çıkarılmakta ve her haberin detay sayfasına HTTP GET isteği gönderilerek haber başlığı, içerik metni ve yayın tarihi elde edilmektedir. Başlık bilgisi öncelikli olarak `og:title` meta etiketinden, içerik ise `og:description` ve `content-text` sınıflı div elementlerindeki paragraflardan çekilmektedir.

B. Veri Temizleme ve Ön İşleme

Çekilen ham veriler üzerinde HTML etiket temizliği, Unicode NFC normalizasyonu ve fazla boşluk giderme işlemleri uygulanmaktadır. Reklam içerikleri ve alakasız bölümler regex tabanlı kalıp eşleştirme ile filtrelenebilir.

C. Haber Türü Sınıflandırma

Her haber, anahtar kelime tabanlı bir sınıflandırma algoritması ile beş kategoriden birine atanmaktadır. Kullanılan anahtar kelimeler Tablo 1’de sunulmuştur. Başlıkta eşleşme sağlayan kelimeler 3 puan, içerikte eşleşenler 1 puan almaktadır. Birden fazla kategoriye giren haberler, öncelik sıralamasına göre (trafik kazası > yangın > elektrik kesintisi > hırsızlık > kültürel etkinlikler) tek bir türe atanmaktadır. Sınıflandırılmayan haberler sisteme dahil edilmemektedir.

Table 1: Haber Türleri ve Anahtar Kelimeler

Haber Türü	Anahtar Kelimeler
Trafik Kazası	kaza, çarpıştı, devrildi, zincirleme
Yangın	yangın, alev, kundak, itfaiye
Elektrik Kesintisi	elektrik, sdaş, trafo
Hırsızlık	hırsız, gasp, soygun, çaldı
Kültürel Etkinlikler	konser, tiyatro, sergi, festival

D. Konum Bilgisi Çıkarımı ve Geocoding

Haber metinlerinden konum bilgisi, çok aşamalı bir yaklaşımla çıkarılmaktadır. İlk aşamada, Kocaeli’nin 12 ilçe adı (İzmit, Gebze, Darıca, Çayirova, Dilovası, Körfez, Derince, Gölcük, Karamürsel, Başiskele, Kartepe, Kandıra) metin içerisinde aranmaktadır. İkinci aşamada, “Mahallesi”, “Sokak”, “Caddesi”, “Bulvarı” gibi kalıplar regex ile tespit edilmektedir. Elde edilen konum metni, Google Geocoding API kullanılarak enlem/boylam koordinatlarına dönüştürülmektedir. API çağrılarını minimize etmek amacıyla, daha önce çözümlenmiş adresler MongoDB üzerinde bir cache koleksiyonunda saklanmaktadır. Kocaeli sınırları dışında kalan koordinatlar filtrelenmektedir.

E. Metin Benzerliği Analizi

Farklı kaynaklarda yayınlanan ancak içerik olarak aynı olan haberlerin tespiti için TF-IDF (Term Frequency-Inverse Document Frequency) vektörizasyonu ve cosine similarity ölçümü kullanılmaktadır. Scikit-learn kütüphanesinin TfidfVectorizer sınıfı ile unigram ve bigram öznitelikleri çıkarılmakta, elde edilen vektörler arasındaki benzerlik oranı hesaplanmaktadır. Benzerlik oranı %90 ve üzeri olan haberler aynı haber olarak kabul edilip birleştirilmekte ve tüm kaynaklar tek kayıt altında listelenmektedir.

F. Veritabanı Yapısı

Veriler MongoDB NoSQL veritabanında yedi temel alan ile saklanmaktadır. Link alanı üzerinde benzersiz indeks tanımlanarak mükerrer kayıt engellenmiştir. Veritabanı yapısının detayları Bölüm IV’te açıklanmaktadır.

G. Sistem Mimarisi

Sistem, modüler bir mimari ile tasarlanmıştır. Her bir işlev ayrı bir Python modülü olarak gerçekleştirilmiştir: scraper.py (veri toplama), preprocessor.py (metin temizleme), classifier.py (sınıflandırma), konum_bulucu.py (geocoding), database.py (veritabanı), similarity.py (benzerlik analizi) ve app.py (arayüz). Scraping işlemi ayrı bir thread üzerinde çalıştırılarak arayüzün yanıt verebilirliği korunmaktadır.

III. Arayüz Konsepti

Kullanıcı arayüzü, Python’un standart GUI kütüphanesi olan Tkinter ve harita görselleştirme için tkintermapview kütüphanesi kullanılarak geliştirilmiştir. Uygulama penceresi Şekil 1’de gösterildiği üzere üç ana bileşenden oluşmaktadır.




Figure 1: Uygulama arayüzü ekran görüntüsü

Sol panel, filtreleme kontrolleri, lejant ve istatistik bölümlerini içermektedir. Kullanıcı, haber türü açılır menüsünden belirli bir kategoriye, ilçe menüsünden belirli bir ilçeyi seçebilmekte ve “Son 1 Gün”, “Son 2 Gün”, “Son 3 Gün” radio butonları ile zaman aralığını belirleyebilmektedir. “Filtrele” butonuna basıldığında, seçili kriterlere uyan haberler MongoDB’den çekilerek harita üzerinde güncellenmektedir.

Üst bar, uygulama başlığını, scraping için gün seçimi radio butonlarını ve “Haberleri Çek” butonunu barındırmaktadır. Bu buton aracılığıyla kullanıcı, seçtiği gün sayısına göre dört haber sitesinin arşiv sayfalarından güncel haberlerin çekilmesini tetikleyebilmektedir. Scraping işlemi ayrı bir thread üzerinde çalıştırılarak arayüzün donması engellenmektedir.

Harita alanı, Google Maps tile servisi kullanılarak Kocaeli merkezli (40.7654°K, 29.9408°D) bir harita görüntülenmektedir. Başlangıç yakınlaştırma seviyesi 11 olarak ayarlanmış olup kullanıcı fare tekerleği ile yakınlaştırma/uzaklaştırma yapabilmektedir. Her haber, türüne göre farklı renkte bir marker ile işaretlenmektedir: trafik kazaları kırmızı, yangınlar turuncu, elektrik kesintileri sarı, hırsızlık olayları mor ve kültürel etkinlikler yeşil renktedir. Marker’a tıklandığında açılan bilgi penceresinde haberin başlığı, tarihi, kaynağı ve konum bilgisi görüntülenmekte, kullanıcıya haberin kaynak sitesine yönlendirme seçeneği sunulmaktadır.

Alt durum çubuğu, sistemin mevcut durumunu ve scraping ilerlemesini anlık olarak göstermektedir. Scraping sırasında hangi kaynağın tarandığı, taranan link sayısı ve bulunan haber sayısı gerçek zamanlı olarak güncellenmektedir.

Arayüzün tamamı Python dilinde, herhangi bir web teknolojisi (HTML, CSS, JavaScript) kullanılmadan geliştirilmiştir. Bu yaklaşım, uygulamanın bağımsız bir masaüstü programı olarak çalışmasını ve web sunucusu gerektirmemesini sağlamıştır.

IV. Veritabanı Yapısı

Projede veri saklama katmanı olarak MongoDB NoSQL veritabanı kullanılmıştır. MongoDB'nin tercih edilmesinin başlıca nedenleri; esnek şema yapısı, JSON benzeri BSON doküman formatı ve yatay ölçeklenebilirlik kapasitesidir [10]. İlişkisel veritabanlarının aksine, MongoDB'de şema değişiklikleri migrasyon gerektirmemekte ve bu durum geliştirme sürecini hızlandırmaktadır [2].

Sistemde iki ana koleksiyon bulunmaktadır. Birincisi, haberlerin saklandığı `haberler` koleksiyonudur. Her haber dokümanı yedi temel alan içermektedir: (1) haber türü, (2) başlık, (3) içerik, (4) konum bilgisi (hem metin hem enlem/boylam koordinatları), (5) yayın tarihi, (6) kaynak site adı ve (7) haber linki. Bunlara ek olarak ilçe bilgisi ve birden fazla kaynaktan geçen haberler için kaynak listesi de saklanmaktadır. İkinci koleksiyon ise `geocode_cache` olup daha önce çözümlenmiş adres-koordinat eşlemelerini tutarak Google Geocoding API'ye yapılan tekrarlı çağrılarını engellemektedir.

Sorgu performansını artırmak amacıyla üç farklı indeks tanımlanmıştır: `link` alanı üzerinde benzersiz (unique) indeks ile mükerrer kayıt engellenmekte, `yayin_tarihi` alanı üzerinde azalan sıralı indeks ile tarih bazlı sorgular hızlandırılmakta ve `haber_turu` alanı üzerinde standart indeks ile filtreleme sorguları optimize edilmektedir. Veritabanı bağlantı bilgileri `.env` dosyasında saklanarak güvenlik sağlanmaktadır.

V. API Entegrasyonu

Projede iki adet Google API kullanılmaktadır: *Google Maps JavaScript API* ve *Google Geocoding API*.

A. Google Geocoding API

Haber metinlerinden çıkarılan konum ifadelerinin (mahalle, sokak, ilçe adı gibi) enlem ve boylam koordinatlarına dönüştürülmesi için Google Geocoding API kullanılmaktadır [3]. API'ye gönderilen isteklerde `language=tr` ve `region=tr` parametreleri ile Türkçe sonuçlar alınması sağlanmakta, `bounds` parametresi ile arama alanı Kocaeli sınırlarına (40.6°K–40.9°K, 29.2°D–30.2°D) daraltılmaktadır. Dönen koordinatlar, Kocaeli sınırları içinde olup olmadığı kontrol edildikten sonra veritabanına kaydedilmektedir.

API çağrı sayısını minimize etmek amacıyla bir cache mekanizması uygulanmıştır. Daha önce çözümlenmiş her adres, MongoDB'deki `geocode_cache` koleksiyonunda saklanmakta ve aynı adres için tekrar API çağrısı yapılmamaktadır. API anahtarı `.env` dosyasında tutularak kaynak koda gömülmesi engellenmiştir.

B. Google Maps Tile Servisi

Harita görselleştirmesi için `tkintermapview` kütüphanesi aracılığıyla Google Maps tile sunucusuna bağlanılmaktadır. Harita, Kocaeli merkez koordinatlarında (40.7654°K, 29.9408°D) ve yakınlaştırma seviyesi 11 ile başlatılmaktadır. Her haber türü için farklı renkte marker oluşturularak harita üzerine yerleştirilmekte ve marker etkileşimleri ile kullanıcıya haber detayları sunulmaktadır.

VI. Sonuç

Bu projede, Kocaeli ili kapsamındaki yerel haber sitelerinden otomatik veri toplama, sınıflandırma ve harita tabanlı görselleştirme işlevlerini bir arada sunan bir masaüstü uygulaması geliştirilmiştir. Sistem, dört farklı haber kaynağının arşiv sayfalarından son üç güne ait haberleri çekmekte, anahtar kelime tabanlı sınıflandırma ile haberleri beş kategoriye ayırmakta ve Google Maps entegrasyonu ile harita üzerinde konumlandırmaktadır.

Geliştirilen sistemin başlıca katkıları: (1) Arşiv sayfası tabanlı scraping ile tarih bazlı sistematik veri toplama, (2) anahtar kelime tabanlı otomatik sınıflandırma, (3) geocoding cache mekanizması ile API çağrılarının azaltılması, (4) TF-IDF tabanlı mükerrer haber tespiti ve (5) modüler Python mimarisi ile genişletilebilirlik şeklinde özetlenebilir.

Proje sürecinde haber sitelerinin HTML yapılarının analizi, konum bilgisinin metinden doğru çıkarılması ve API sınırlamalarının yönetilmesi başlıca zorluklar olarak karşılaşılmıştır. Gelecek çalışmalarda makine öğrenmesi tabanlı sınıflandırma (BERT, SVM), NER tabanlı konum çıkarımı ve web arayüzü desteği planlanmaktadır.

VII. Yazar Katkıları

Bu proje, Kağan Can Kaba tarafından bireysel olarak tasarlanmış ve geliştirilmiştir. Yazar; sistem mimarisi tasarımı, web scraping modülünün geliştirilmesi, haber sınıflandırma algoritmasının kodlanması, konum çıkarımı ve geocoding entegrasyonu, MongoDB veritabanı yapısının oluşturulması, metin benzerliği analizinin uygulanması, Tkinter tabanlı masaüstü arayüzünün geliştirilmesi ve IEEE formatında proje raporunun hazırlanması süreçlerinin tamamını yürütmüştür.

Kaynakça

- [1] L. Richardson, "Beautiful Soup Documentation," *crummy.com*, 2023. [Çevrimiçi]. Erişim: <https://www.crummy.com/software/BeautifulSoup/bs4/doc/>
- [2] MongoDB Inc., "MongoDB Documentation," 2024. [Çevrimiçi]. Erişim: <https://docs.mongodb.com/>
- [3] Google Developers, "Geocoding API Documentation," 2024. [Çevrimiçi]. Erişim: <https://developers.google.com/maps/documentation/geocoding>
- [4] F. Pedregosa *et al.*, "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, cilt 12, ss. 2825–2830, 2011.
- [5] G. Salton ve C. Buckley, "Term-weighting approaches in automatic text retrieval," *Information Processing & Management*, cilt 24, sayı 5, ss. 513–523, 1988.
- [6] R. Mitchell, *Web Scraping with Python: Collecting More Data from the Modern Web*, 2. baskı, O'Reilly Media, 2018.

- [7] J. Shipman, “Tkinter 8.5 Reference: A GUI for Python,” *New Mexico Tech Computer Center*, 2013.
- [8] A. Huang, “Similarity measures for text document clustering,” *Proc. New Zealand Computer Science Research Student Conference*, ss. 49–56, 2008.
- [9] S. Bird, E. Klein ve E. Loper, *Natural Language Processing with Python*, O’Reilly Media, 2009.
- [10] P. J. Sadalage ve M. Fowler, *NoSQL Distilled: A Brief Guide to the Emerging World of Polyglot Persistence*, Addison-Wesley, 2012.